


꼬맨틀

SEMANTLE

꼬맨틀 연구원 문승은



INDEX

•
꼬맨틀이란?

•
단어 유사도

•
코드 풀어보기

•
꼬맨틀 팁

•
실전!!

꼬맨틀이란?

 데이터 활용에 가치를 더하는 데이터 시각화, NEWSJELLY

꼬맨틀 - 단어 유사도 추측 게임

1300번째 꼬맨틀의 정답 단어를 맞춰보세요.

정답 단어와 가장 유사한 단어의 유사도는 **58.61** 입니다.

10번째로 유사한 단어의 유사도는 52.74이고, 1,000번째로 유사한 단어의 유사도는 33.41 입니다.

정답을 모르겠다면?
꼬맨틀  공략집 

꼬맨틀은 오늘의 단어를 맞추는 게임입니다.

정답 단어를 추측하면, 추측한 단어가 정답 단어와 얼마나 유사한지 유사도 점수로 알려줍니다.

가장 유사한 단어의 유사도와 가까운 단어를 추측하면서, 정답 단어를 맞춰보세요.

유사도란?

수치적 표현

추측한 단어와 정답 단어가 의미맥락적으로 얼마나 비슷한지에 대한 정도를 -100에서 +100까지의 숫자로 계산한 점수

꼬맨틀의 유사도

철자의 유사도 X, 의미보단 동일한 맥락(문맥)에서 사용되는지가 더 중요

예). 반대의 의미를 갖더라도 유사한 맥락에 사용된다면 유사도 가 비슷 -> 사랑과 증오

동일한 맥락

의미적으로는 아무 관계도 없지만, 동일한 맥락에서 많이 쓰이는 경우: 시끄럽다, 조용하다

동일한 문장에서의 사용

의미적으로는 아무 관계도 없지만 동일한 문장에서 많이 쓰이는 경우: 음식물, 쓰레기통

코드 풀어보기

꼬맨틀 — 단어 유사도 추측 게임

이 레포지터리는 Johannes Gätjen의 [Semantlich](#) ([소스코드](#))를 포크하여, 한국어로 플레이할 수 있도록 수정한 것입니다.

Setup

Download Word2Vec and dictionary data:

```
cd data
wget https://dl.fbaipublicfiles.com/fasttext/vectors-crawl/cc.ko.300.vec.gz
gzip -d cc.ko.300.vec.gz
wget https://github.com/spellcheck-ko/hunspell-dict-ko/releases/download/0.7.92/ko-aff-dic-0.7.92.zip
unzip ko-aff-dic-0.7.92.zip
```

Filter and save word2vec in DB

```
docker-compose run --rm --entrypoint python app filter_words.py
docker-compose run --rm --entrypoint python app process_vecs.py
```

(Optional) Regenerate secrets

```
docker-compose run --rm --entrypoint python app generate_secrets.py
```

Start server

```
docker-compose up
```


FASTTEXT

FASTTEXT는 WORD2VEC을 확장한 단어 임베딩 방법입니다.

다른점?

WORD2VEC

단어를 기반으로 학습

FASTTEXT

단어 하나를 N-GRAM으로
벡터화하여 학습

FASTTEXT 장점

모르는 단어에 대한 대응이 가능하다

"birthplace" 라는 단어가 존재하지 않을 때
"birth"와 "place"단어가 있다면 "birthplace"의 벡터를 얻을 수 있다 !!


희귀한 단어에 대한 대응이 가능하다

예: "먹었었다:"

→ "ㄱ ㅏ ㅓ ㅗ ㅓ ㅗ ㅓ ㅓ ㅓ"

ㄱ ㅏ ㅓ, ㅗ ㅓ ㅓ, ㅓ ㅓ

위의 3개와 같은 조각은 매우 많이 등장




노이즈가 많은 코퍼스에서 강점을 가짐
특히, 오타가 섞인 단어는 빈도수가 매우 적으므로 good

CBOW continuous bag of words

주어진 단어를 통해 중심 단어를 예측하며 단어 벡터 계산

나는 어제 마트에서 사과를 샀다.



나는 어제 마트에서 ??? 를 샀다.

입력(주변단어)

[나는, 어제, 마트에서, 샀다]


타겟(중심 단어)

[사과]

1. 마트에서를 N-GRAM 조각들로 분해합니다
 - a. $\langle \square \uparrow \uparrow \square \square \square \square \rangle \rightarrow \langle \square \uparrow, \square \uparrow \uparrow, \uparrow \uparrow \square, \dots \rangle$
2. 각 조각들의 임베딩 벡터를 가져옵니다
3. 모두 더하거나 평균내어 "마트에서"라는 단어 1개의 최종벡터를 만듭니다
4. 만들어진 주변 단어 4개를 모두 더하거나 평균을 내어 "최종 문맥 벡터"를 생성합니다
5. 문맥 벡터를 신경망에 입력하여 타겟인 사과를 예측하고 틀리면 BACKPROPAGATION하여 벡터를 업데이트합니다.


SKIP-GRAM

나는 어제 마트에서 사과를 샀다. [나는, 어제, 마트에서, 사과를, 샀다]




- (QUIZ 1) INPUT: `[사과를]` → TARGET: `[나는]`
- (QUIZ 2) INPUT: `[사과를]` → TARGET: `[어제]`
- (QUIZ 3) INPUT: `[사과를]` → TARGET: `[마트에서]`
- (QUIZ 4) INPUT: `[사과를]` → TARGET: `[샀다]`

1. INPUT에 [사과를]의 벡터를 넣습니다
2. 퀴즈3에서 정답은 [마트에서]입니다
3. 잘못 예측하면 [사과를]과 [마트에서]가 더 가까워
지도록 벡터를 업데이트합니다.
4. 퀴즈 1~4 모두 반복합니다.



CBOW



Skip-gram

코드 풀어보기

```
def most_similar(mat: array, idx: int, k: int) -> Tuple[array, array]:  
    vec = mat[idx]  
    dists = mat.dot(vec) / (np.linalg.norm(mat, axis=1) * np.linalg.norm(vec))  
    top_idxes = np.argpartition(dists, -k)[-k:]  
    dist_sort_args = dists[top_idxes].argsort()[::-1]  
    return top_idxes[dist_sort_args], dists[top_idxes][dist_sort_args]
```


$$\text{similarity} = \cos(\Theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

코사인 유사도

-1~1의 값을 가지며 1에 가까울수록 유사도가 높음.

꼬맨틀 TIP1. 시작 시 입력

모든 정답 단어 품사 비율



1. 품사 찾기

정답의 대부분은 명사임을 기억하기

명사 중에는 실체가 있는 물건 VS 추상명사 구분


한 품사가 계속해서 낮은 정답률을 보인다면 빠르게 다른 품사로 접근

'동사' '명사' '형용사' '의성어, 의태어' '접속사' '지시사' 등을 고루 넣으면서 1000위 안에 드는 단어를 먼저 찾기

2. 단어 리스트 만들기

예). 사랑, 우정을 먼저 써보자

=> 사랑, 우정이 높게 나왔을 경우 가족이나 친구, 지인 등으로 좁혀나갈 수 있음!



꼬맨틀 TIP2. 좁혀나가기

동일한 맥락

의미적으로는 아무 관계도 없지만, 동일한 맥락에서 많이 쓰이는 경우: 시끄럽다, 조용하다

동일한 문장에서의 사용

의미적으로는 아무 관계도 없지만 동일한 문장에서 많이 쓰이는 경우: 음식물, 쓰레기통

꼬맨틀의 유사도

꼬맨틀의 유사도는 단어의 종류가 같음을 봄

EX. 단어가 대학교라면, 높은 유사도는 학생, 교수 등이 아닌 고등학교, 중학교.

꼬맨틀 #1301의 정답은 유물입니다. 가장 유사한 단어는 다음과 같습니다:

유사도 순위	단어	유사도
1	출토	56.92
2	유적	56.18
3	출토품	52.27
4	전시물	48.01
5	발굴	47.24
6	유품	47.24
7	서책	46.43
8	발굴지	46.25
9	유골	46.12
10	고미술	45.71
11	고증	45.67
12	문물	45.34
13	석불	45.29
14	고문헌	45.21
15	거석	44.99
16	단청	44.96
17	고서	44.90
18	전시품	44.56
19	문화재	44.45
20	고궁	44.18

977	독침	30.21
978	독침	30.21
979	판매대	30.21
980	요괴	30.20
981	전시되어	30.20
982	민속학	30.20
983	늑골	30.20
984	일괄	30.19
985	직명	30.19
986	국학	30.19
987	이단	30.18
988	잔해	30.18
989	기념주화	30.18
990	지참	30.18
991	종파	30.18
992	최신	30.18
993	정착지	30.18
994	쇄	30.17
995	종류	30.17
996	상고	30.17
997	손톱	30.16
998	판시	30.16
999	비늘	30.15



꼬맨틀 TIP3. 막힐 땐?

1. 사전활용


높은 순위에 도달했는데 막히는 경우에는 국어사전이나 포털사이트에서 최고 순위 단어의 유의어를 찾자!
그래도 모르겠다면 다른 친구들과 순위 리스트를 공유하면서 힌트를 주고받기!

2. 과감한 방향 전환

너무 막힌다면 과감하게 현재 밀고 나가고 있는 분야를 포기하고 완전히 새로운 것들을 쳐보자!
이상한 데에 빠져서 삽질하고 있을 수 있음!
꼬맨틀이 가끔 정신이 나가서 이상한 단어를 유사도 높다고 제시할 때도 있기 때문..



오늘의 꼬맨틀 도전해보자



감사합니다

참고자료: 꼬맨틀 사이트, 공략집, Efficient Estimation of Word Representations in Vector Space 논문 그림, 딥 러닝을 이용한 자연어 처리 입문 (위키독스)